Proyecto EL4106 - Semestre Otoño 2024

Profesor: Javier Ruiz del Solar
Auxiliar: Patricio Loncomilla.

Publicación enunciado: 25 de Junio de 2024
Presentación final proyecto: 17 de Julio de 2024

El objetivo de este proyecto es implementar un clasificador de actividades físicas. Se utilizará una versión modificada de la base de datos *UCF-iPhone Dataset*, cuya versión original está disponible en:

https://www.crcv.ucf.edu/data/UCF-iPhone.php

Esta base de datos contiene mediciones de personas realizando diferentes actividades físicas (9 diferentes actividades), medidas con una IMU (unidad de mediciones inerciales, sigla del inglés) de un Apple IPhone 4. La IMU incluye un acelerómetro 3D, un giroscopio de 3 ejes y un magnetómetro de 3 ejes. Las actividades físicas (clases) para las cuales se realizaron las mediciones son:

- Clase 0: andar en bicicleta
- Clase 1: subir escaleras
- Clase 2: bajar escaleras
- Clase 3: andar en bicicleta en gimnasio
- Clase 4: saltar la cuerda
- Clase 5: correr
- Clase 6: estar de pie
- Clase 7: caminar en trotadora
- Clase 8: caminar

Para cada actividad se tomaron muestras a 60 [Hz] de cada uno de los sensores, las cuales fueron reducidas a ventanas de 500 muestras (8.33 [s]). **A partir del conjunto de datos original, se generó un nuevo conjunto para poder desarrollar el proyecto. Las ventanas con clase 0 fueron eliminadas, debido a lo cual el conjunto de datos entregado contiene sólo las clases 1 a 8.** El conjunto entregado tiene un total de 4368 ventanas de entrenamiento/validación y 1280 ventanas de prueba por cada señal, con ventanas de tamaño 125 muestras. Las etiquetas del conjunto de prueba no estarán disponibles para el desarrollo del proyecto y serán utilizadas solo para su evaluación.

Se les pide diseñar, implementar, entrenar y validar un sistema de clasificación que reciba estas 9 señales de entrada y que determine la acción realizada (clase). Existe la posibilidad de que usted determine que no necesariamente las 9 señales deben ser usadas, sino un número menor.

Para lograr esto necesitará (todos los pasos deben ser reportados):

(1) Realizar un programa que permita leer la base de datos. Esta consiste en dos archivos .csv (separado por comas) df_smartphone_trainval.csv y df_smartphone_test.csv. Se recomienda leerlos usando el paquete *pandas*. El alumno debe generar conjuntos de entrenamiento y validación a partir de df_smartphone_trainval.csv (los conjuntos de entrenamiento y validación deben incluir personas distintas). El archivo df_smartphone_test.csv contiene los datos del conjunto de prueba, pero no sus etiquetas.

(2) Graficar algunas señales del conjunto de datos. Esto puede facilitar la comprensión del problema a resolver y la naturaleza de las señales a ser analizadas.

(3) Investigar el aporte de cada señal de entrada en la solución del problema, y en caso de ser necesario, tome decisiones respecto de la exclusión de alguna(s) de esta(s). Debe justificarse claramente el hecho de eliminar o no señales a partir del análisis realizado a los datos.

(4) Evaluar si se requiere aplicar algún tipo de filtrado a las señales (pasa bajos, pasa altos o pasa bandas) o algún tipo de pre-procesamiento. En el caso que se requiera, implementar estas operaciones.

(5) Definir las características a ser utilizadas e implementar su cálculo. Se recomienda usar características calculadas sobre cada canal, como las medias, varianzas, valores mínimos y máximos, rangos de las variables, etcétera. Se recomienda normalizar las características, usando las estadísticas del conjunto de entrenamiento (no las de validación). Como referencia, considere las características definidas en los papers [1] [2] subidos a u-cursos.

(6) Aplicar algún método de selección de características para determinar un conjunto reducido de características (aproximadamente el 50% de las características definidas en el punto anterior) a ser usadas para entrenar el clasificador.

(7) Elegir y entrenar un clasificador o cascada de clasificadores [2] para determinar la actividad física realizada. Usted es libre de utilizar el o los clasificadores que le parezcan más apropiados y que resuelvan de mejor manera el problema (Bayes, Redes Neuronales, SVM, Adaboost, Random Forest, redes deep, etc.).
   - Se debe probar con al menos 2 tipos de clasificadores distintos, usando tanto el conjunto de características completo (definido en (5)) como el conjunto reducido (definido en (6)). Es decir, considerando el número de clasificadores a ser utilizados y el número de características a ser consideradas, se debe entrenar al menos 4 clasificadores.
   - Recuerde utilizar el conjunto de validación para elegir los hiperparámetros, y si corresponde, para evitar el sobreajuste del clasificador.
   - Recuerde caracterizar los resultados obtenidos usando el conjunto de validación y las métricas apropiadas (matriz de confusión, accuracy, etc.).

(8) Aplique el mejor clasificador obtenido sobre los datos del conjunto de prueba. Luego, suba el archivo con las clases predichas a la plataforma Kaggle (se indicará el link de la competencia en el foro, así como las instrucciones de uso). Se debe notar que se puede subir el archivo con etiquetas más de una vez, pero con un límite diario.

Importante: Todos los pasos anteriormente descritos (8 pasos) deben ser realizados (y reportados), aunque no necesariamente en el orden solicitado, pues pudiera ser que haya que iterar entre estos.

Importante: En el caso en que se utilice un clasificador de tipo *deep learning*, no es necesario realizar definición de características, selección de características, ni tampoco el entrenamiento de clasificadores como ítems separados, ya que la red realiza estas tareas.

El proyecto debe realizarse en Python 3, con bibliotecas de machine learning estándares (scikit-learn, pandas, scipy, pytorch, tensorflow, etc.), instaladas en forma local o usando colaboratory. En este último caso, se recomienda primero bajar el archivo .zip comprimido y luego descomprimirlo usando la siguiente línea en el notebook:

```
!unzip dataset_2024_full_alumnos_v01.zip
```

Evaluación final

1. Presentación oral (grabada) e informe escrito, donde se explique la metodología utilizada, las mejoras de los clasificadores obtenidas al aplicar selección de características, los resultados finales obtenidos con los clasificadores escogidos, las métricas (matriz de confusión y accuracy) sobre el conjunto de validación, el score y ranking en el conjunto de prueba, así como los problemas encontrados y posibles mejoras al sistema (70%).
2. Resultado obtenido en kaggle (30%)

Las presentaciones orales grabadas deben ser de máximo 3 minutos. Recuerde considerar el público objetivo, no pierda tiempo explicando la base de datos u otra información que todos conocen. Las presentaciones deben ser entregadas de forma electrónica (en u-cursos), así como el informe final en formato PDF. Además, el informe final en PDF debe ser subido a la plataforma Turnitin.

Adicionalmente, se deberán subir los códigos del proyecto a u-cursos. Incluir un corto archivo de texto explicando cómo se utiliza su programa.

El proyecto debe realizarse en forma individual. Las entregas atrasadas serán penalizadas con un punto de descuento por cada día de atraso, incluyendo fines de semana. Se abrirá un tema en el foro para consultas.

Importante: La evaluación considerará el correcto funcionamiento del programa, **la calidad del clasificador obtenido**, la inclusión de los resultados en el informe, la calidad de los experimentos realizados y de su análisis, así como la forma, prolijidad y calidad de este.

Recomendación: Si se quiere usar pytorch, se recomienda trabajar inicialmente con scikit-learn para poder familiarizarse con el problema.

Nota: Las etiquetas del conjunto de prueba no están disponibles. Se usará Kaggle para implementar un leaderboard público y otro privado (oculto) que permita *rankear* los resultados subidos por los alumnos. Dado que Kaggle no entrega matrices de confusión, almacene en su computador el archivo con las etiquetas predichas antes de subirlas. Se debe notar que durante el desarrollo del proyecto sólo se interactuará con las etiquetas reales a través del *leaderboard* público, el cual será usado para establecer el ranking en el proyecto (el *leaderboard* privado se ignorará).

Papers relacionados:

[1] D. Anguita, A. Ghio, L. Oneto, X. Parra, Jorge Luis Reyes-Ortiz. A Public Domain Dataset for Human Activity Recognition using Smartphones. Published in The European Symposium on Artificial Neural Networks 2013.

[2] Kishore Reddy, Mubarak Shah. Macro-class selection for hierarchical k-nn classification of inertial sensor data. PECCS 2012.