Tarea 2 EL4106 - Semestre Otoño 2024

Profesor: Javier Ruiz del Solar
Auxiliar: Patricio Loncomilla

Fecha enunciado: 16 de Abril de 2024
Plazo entrega tarea: 6 de Mayo de 2024

El objetivo de esta tarea es implementar un clasificador de calidad de vino usando *Support Vector Machine* (SVM). Se usará el conjunto de datos Wine Quality Data Set, el cual forma parte del *UC Irvine Machine Learning Repository*. El conjunto de datos contiene 11 características fisicoquímicas medidas para cada muestra de vino. El conjunto de datos contiene 12 columnas: las primeras 11 son las características y la última es la calidad del vino, un número entre 0 y 10. Se entrega un archivo llamado winequality-all.csv que contiene todas las muestras de vino.

Se pide utilizar la metodología de clasificación estadística SVM para entrenar y validar un clasificador de calidad de vino. El trabajo a realizar incluye analizar detalladamente el efecto en el rendimiento del clasificador de la utilización de distintos hiper-parámetros (variable C, tipo kernel, parámetro del kernel).

Los kernels de SVM a utilizar, incluyendo sus hiper-parámetros, son:

- Lineal: $K(x_i, x_j) = x_i^T x_j$
- Polinomial: $K(x_i, x_j) = (\gamma x_i^T x_j + r)^d$
- RBF: $K(x_i, x_j) = \exp\left(-\gamma \left\| x_i^T x_j \right\|^2\right)$

Se pide:

1) Implementar un código que lea el dataset, usando pandas. Se definirán dos clases para las muestras de vino: *calidad alta* y *calidad baja*. Generar una nueva columna que contenga la clase de las muestras. Para lograr esto, se debe crear una nueva columna llamada `'class'`, la cual debe tener valor `1` (calidad alta, clase positiva) cuando `quality>=6`, y valor `0` (calidad baja, clase negativa) en caso contrario. Luego, eliminar la columna `'quality'`.

2) Dividir la base de datos en 3 conjuntos representativos: entrenamiento (60%), validación (20%) y prueba (20%). Compruebe la representatividad de estos, verificando si la proporción de cada clase se mantiene cercana a la proporción del conjunto completo.

3) Entrene un MinMaxScaler (disponible en scikit-learn) usando las características del conjunto de entrenamiento para poder normalizar las características. Luego, aplíquelo a las características del conjunto de entrenamiento, validación y prueba.

4) SVM lineal

   - Entrenar un clasificador SVM lineal que permita discriminar la clase positiva de la clase negativa, usando el clasificador SVC de *scikit-learn*. Para obtener un buen clasificador se debe usar una grilla para buscar los mejores hiper-parámetros para el clasificador (parámetro C en este caso). En esta tarea, en el *grid search* se debe usar el conjunto de validación para evaluar la calidad de los hiper-parámetros. Use 5 valores de C. Además, se debe indicar el tiempo de entrenamiento.

   - Evaluar el mejor clasificador obtenido, i.e. el que tiene los mejores hiperparámetros, sobre el conjunto de validación y generar la matriz de confusión, tanto en su versión normalizada como no normalizada. Se recomienda usar la función metrics.confusión_matrix( ) de *scikit-learn*. También

generar una curva ROC que muestre el desempeño del clasificador y calcular el área bajo la curva. Se debe usar las funciones decision_function( ), metrics.roc_curve() y metrics.auc( ) de *scikit-learn*. Finalmente, generar una curva *precisión-recall* y calcular el *average precision*. Usar las funciones decision_function( ), metrics.precision_recall_curve( ) y metrics.average_precision_score( ) de *scikit-learn*.

5) SVM Polinomial

- Repetir los pasos detallados en (4) para el caso de un SVM con kernel polinomial. Usar 3 valores de C y 3 valores distintos del grado del polinomio para la grilla de búsqueda (de hiperparámetros). Se debe usar el $gamma$ por defecto para el kernel polinomial de sklearn, además de $r = 1$.

6) SVM RBF

- Repetir los pasos detallados en (4) para el caso de un SVM con kernel RBF. Usar 5 valores de C y 4 valores de gamma (parámetro del kernel) para la grilla de búsqueda (de hiper-parámetros).

7) Evaluar los mejores clasificadores obtenidos en (4), (5) y (6) (un único clasificador en cada caso) sobre el conjunto de prueba, reportando: matriz de confusión, curva ROC, curva precisión-recall y average precisión.

8) Analice el rendimiento de los clasificadores entrenados, considerando las métricas obtenidas en (7) y el tiempo de entrenamiento.

Para evaluar la grilla sobre el conjunto de validación, averigüe sobre el uso de PredefinedSplit de *scikit-learn*. Se debe notar que la función fit() de GridSearchCV, una vez encontrados los mejores hiper-parámetros, entrena el sistema usando tanto el conjunto de entrenamiento como el de validación concatenados de forma automática. En consecuencia, el clasificador con los mejores hiper-parámetros encontrados debe ser reentrenado usando sólo el conjunto de entrenamiento.

Los informes y códigos deben ser subidos a u-cursos a más tardar el día lunes 6 de mayo a las 23:59. Incluir un breve archivo de texto explicando cómo se utiliza su programa. Las tareas atrasadas serán penalizadas con un punto base por cada día de atraso (incluyendo fines de semana).

Nota: Dado que el entrenamiento del SVM con grillas puede demorar, se puede usar un número menor de muestras mientras se verifica el correcto funcionamiento del código.

Nota: Se pide generar métricas y curvas tanto para el conjunto de validación como para el de entrenamiento.

Nota: Para que los resultados sean repetibles, se debe usar un random_state fijo para las funciones cuyo comportamiento sea aleatorio.

Importante: La evaluación de la tarea considerará el correcto funcionamiento del programa, la inclusión de los resultados de los pasos pedidos en el informe, la calidad de los experimentos realizados y de su análisis, la inclusión de las partes importantes del código en el informe, así como la forma, prolijidad y calidad de este. Se debe usar el formato de informe indicado en material docente.

Nota: El informe, en formato pdf, debe ser subido a turnitin, en el siguiente enlace:

https://uchile.turnitin.com/originality/hand-in-link?jwt=eyJ0eXAiOiJKV1QiLCJhbGciOiJIUzI1NiJ9.eyJyZWR3b29kSWQiOiIzYzgxZGQ2Yi01OWE2LTQ2MGEtODE2OC01MGI0OWM1Y2YyYTEiLCJleHAiOjE3MTcxNzMwMDAsImlhdCI6MTcxMjc2NjcyOCwianRpIjoiMDI2ZTAyZWEtMjhmMS00YzNjLTk0MWItYmI0ZWMxZTUyNzg1IiwidGVuYW50IjoidWNoaWxlIiwiZm9sZGVySWQiOiJmYzU4MzAzZS00ZDI

1LTQ4MjQtOWUwZi0xMWRhNTYwMWIzN2MifQ.z41bkRRacJ4M556mXEGJo0BfRNZxQJpcmbrI6Ovd5ok