Tarea 3 – Selección de Características
EL4106 - Semestre Otoño 2024

Profesor: Javier Ruiz del Solar
Auxiliar: Patricio Loncomilla

Fecha enunciado: 7 de Abril de 2024
Plazo entrega tarea: 20 de Mayo de 2024

El objetivo de esta tarea es hacer selección de características, para un problema de clasificación de riesgo cardíaco. Se utilizará el conjunto de datos: *Heart Disease.* Este conjunto tiene 13 características, con 2 clases y 297 muestras válidas en total. La base de datos (el archivo processed.cleveland.data) estará disponible tanto en u-cursos como en la siguiente página:

https://archive.ics.uci.edu/dataset/45/heart+disease

En esta aplicación, la obtención de la mayoría de las características requiere realizar exámenes médicos a pacientes, por lo cual reducir su número es importante.

Se les pide usar scikit-learn para analizar los datos, entrenar clasificadores y encontrar un subconjunto reducido de características que permita resolver el problema.

En esta tarea se usarán como clasificadores estadísticos SVM lineal y Random Forest. Los hiperparámetros que se deben considerar en estos son:

Para SVM lineal: C = [0.0001, 0.001, 0.1].
Para Random Forest: max_depth = 8, y n_estimators = [50, 100, …, 250]

Se pide realizar los siguientes pasos:

1) Selección de Características y Entrenamiento
   a) Leer el archivo de datos usando pandas. Las clases a detectar son cero (variable 'num' < 2) y uno (variable 'num' >= 2). Genere la columna 'class' a partir de la columna 'num', y luego elimine la columna 'num'. Además, elimine las filas con datos faltantes (contienen el carácter '?'). Los nombres de las características están en la página del repositorio.
   b) Dividir el dataset en entrenamiento (60%), validación (20%) y prueba (20%) usando train_test_split.
   c) Preprocesar las características usando un StandardScaler
   d) Realizar una clasificación inicial usando un clasificador SVM lineal. Se debe usar una grilla sobre el hiperparámetro C. En esta tarea, en el grid search se debe usar el conjunto de validación para evaluar la calidad de los hiperparámetros. Además, se debe indicar el tiempo de entrenamiento.
   e) Generar una matriz de confusión normalizada para el clasificador inicial, calculando además el *accuracy*, usando el conjunto de validación. Se debe usar sns.heatmap( ) para mostrar la matriz de confusión.
   f) Realizar selección de características usando SelectFromModel (un clasificador de tipo *wrapper*), usando el mejor clasificador encontrado en el punto anterior (el que contiene los mejores hiperparámetros). Indique cuáles son las características seleccionadas
   g) Entrenar un segundo clasificador con el conjunto de características reducido, usando una grilla sobre el hiperparámetro C, indicando el tiempo de entrenamiento. Generar una matriz de confusión normalizada para el clasificador con características reducidas, calculando además el *accuracy*, usando el conjunto de validación. Se debe usar sns.heatmap( ) para mostrar la matriz de confusión.
   h) Repetir el paso (g) usando un clasificador SVM lineal, eligiendo las 6 mejores características encontradas por SelectKBest (método de tipo filtro), usando una grilla sobre el hiperparámetro C.
   i) Repetir el paso (g) usando un clasificador SVM lineal, eligiendo las 3 mejores características encontradas por SelectKBest, usando una grilla sobre el hiperparámetro C.

j) Repetir los pasos (d) y (e) usando un clasificador RandomForest, con una profundidad de 8 (max_depth = 8) y usando una grilla sobre el hiperparámetro n_estimators, usando todas las características.
k) Repetir el paso (f) usando un clasificador RandomForest, usando el selector de características SelectFromModel y usando una grilla sobre el hiperparámetro n_estimators al entrenar.
l) Repetir el paso (g) usando un clasificador RandomForest, eligiendo las 6 mejores características encontradas por SelectKBest y usando una grilla sobre el hiperparámetro n_estimators al entrenar.
m) Repetir el paso (g) usando un clasificador RandomForest, eligiendo las 3 mejores características encontradas por SelectKBest y usando una grilla sobre el hiperparámetro n_estimators al entrenar.
n) Evalúe el mejor clasificador SVM y el mejor clasificador Random Forest encontrados con características reducidas sobre el conjunto de prueba, indicando sus matrices de confusión normalizadas y sus *accuracies*

2) Análisis
   a) Indique qué tipo de clasificador,SVM lineal o Random Forest, entrega en general mejores resultados
   b) Indique el efecto de reducir características sobre el *accuracy* obtenido. Considere el número de características seleccionadas v/s el *accuracy* obtenido, además del tiempo de entrenamiento.
   c) Considerando los resultados de los dos puntos anteriores y el problema a resolver, analice la utilidad de la reducción de características para el conjunto de datos usado.

Para poder evaluar la grilla usando el conjunto de validación, averigüe sobre el uso de PredefinedSplit de scikit-learn. Note que el mejor clasificador encontrado usando la grilla debe ser reentrenado con los datos del conjunto de entrenamiento después de encontrar los mejores hiperparámetros.

Además, al usar train_test_split y al entrenar los random forest, se debe usar un random_state fijo, para que los resultados sean repetibles.

Los informes y códigos deben ser subidos a u-cursos a más tardar a las 23:59 del día 20 de mayo.

Se recuerda que la estructura esperada para los informes se encuentra en u-cursos. Además, los informes deben estar en formato PDF, y los códigos relevantes para cada sección deben ser agregados como texto (no como imágenes). Recuerde agregar el código como texto plano en el anexo. Finalmente, el informe debe ser un PDF creado con Word o latex, para que pueda ser parseado/analizado por turnitin.

Además, si el notebook no se ejecuta directamente celda por celda (su ejecución no es directa), se debe adjuntar un archivo README. El notebook se debe subir junto con el informe.

Importante: La evaluación de la tarea considerará la inclusión de los resultados de los pasos pedidos en el informe, la calidad de los experimentos realizados y de su análisis, la inclusión de las partes importantes del código en el informe, así como la forma, prolijidad y calidad del mismo.

Nota: Los informes en PDF deben ser subidos a la plataforma turnitin. El link es el siguiente:

https://uchile.turnitin.com/originality/hand-in-link?jwt=eyJ0eXAiOiJKV1QiLCJhbGciOiJIUzI1NiJ9.eyJyZWR3b29kSWQiOiIzYzgxZGQ2Yi01OWE2LTQ2MGEtODE2OC01MGI0OWM1Y2YyYTEiLCJleHAiOjE3MTgyMDQxMDAsImlhdCI6MTcxNTA5MzU4OCwianRpIjoiYTQ4MzBkMWMtNzY3Mi00ODExLTk5ZTItNzMwYWUxYjdhMjZiIiwidGVuYW50IjoidWNoaWxlIiwiZm9sZGVyIjoiI2YjYxM2QxMC0wZDU2LTQ2ODAtYjA3ZS01MjQ1MjRmYTNmMGYifQ.CxrtOnrssmomz4IbIK0YL72-0R4Or_7-26xXLyVF-kc