Tarea 5 EL4106 - Semestre Otoño 2024

Profesor: Javier Ruiz del Solar
Auxiliar: Patricio Loncomilla

Fecha enunciado: 10 de Junio de 2024
Plazo entrega tarea: 23 de Junio de 2024

El objetivo de esta tarea es utilizar distintos algoritmos de clustering y analizar su desempeño. Se utilizará la base de datos *Mice Protein Expression Data Set*, que es una base de datos tomadas del *UC Irvine Machine Learning Repository*. Contiene niveles de expresión de 77 proteínas medidas en fracciones nucleares de células de ratones, en la corteza cerebral. Hay 38 ratones de control y 34 ratones trisómicos (síndrome de Down). Dado que algunos ratones fueron estimulados para aprender y/o inyectados con memantina, hay 8 grupos en total. Los grupos son:

- c-CS-s: ratones de control, estimulados para aprender, inyectados con solución salina (9 ratones)
- c-CS-m: ratones de control, estimulados para aprender, inyectados con memantina (10 ratones)
- c-SC-s: ratones de control, no estimulados para aprender, inyectados con solución salina (9 ratones)
- c-SC-m: ratones de control, no estimulados para aprender, inyectados con memantina (10 ratones)
- t-CS-s: ratones con trisomía, estimulados para aprender, inyectados con solución salina (7 ratones)
- t-CS-m: ratones con trisomía, estimulados para aprender, inyectados con memantina (9 ratones)
- t-SC-s: ratones con trisomía, no estimulados para aprender, inyectados con solución salina (9 ratones)
- t-SC-m: ratones con trisomía, no estimulados para aprender, inyectados con memantina (9 ratones)

La base de datos se puede bajar desde la siguiente dirección:

https://archive.ics.uci.edu/ml/datasets/Mice+Protein+Expression

Para poder realizar el trabajo, se usará el siguiente código base (basado en scikit-learn):

https://scikit-learn.org/stable/auto_examples/cluster/plot_kmeans_digits.html#sphx-glr-auto-examples-cluster-plot-kmeans-digits-py

Se pide utilizar tres algoritmos de clustering en este trabajo: k-means, DBSCAN y clustering aglomerativo.

1) Implemente un código que lea la base de datos. Se recomienda usar la biblioteca Pandas. Se debe eliminar la columna `BCL2_N`, dado que contiene muchos valores NaN. Asimismo, las filas que contienen valores NaN deben ser eliminadas. Finalmente, para esta tarea, se recomienda no usar scale( ) sobre los datos.

2) Modifique la función bench_k_means( ) en el código base, agregando una columna extra, correspondiente al número de clusters.

3) Implemente una nueva función bench_clustering2( ), tomando como base la función bench_k_means( ) modificada en el punto anterior. Esta función será usada para obtener un benchmark tanto de DBSCAN como del clustering aglomerativo, y se debe implementar debido a que estos dos métodos no poseen la variable inertia_, debido a lo cual no hay que imprimirla.

   Notar que:
   a. DBSCAN no asigna todas las muestras a un cluster, las muestras no asociadas tienen label "-1". Debido a esto, la función bench_clustering2( ) debe entregar la opción de: (i) calcular las

métricas sólo con los datos asociados, o (ii) calcular las métricas usando todos los datos, asumiendo que los datos no asociados conforman un cluster extra. Dicha opción debe ser implementada usando una variable extra (True/False) que se le entrega a la función.
   b. El algoritmo DBSCAN genera una cantidad variable de clusters.
   c. En algunos casos, dependiendo de los hiperparámetros elegidos, es posible que DBSCAN no encuentre clusters, o bien encuentre uno solo, lo cual imposibilita calcular las métricas. Decida una estrategia para manejar estos casos.

4) Entrenar los siguientes algoritmos de clustering, con los parámetros especificados:
   a. K-Means (con inicialización **al azar**), usando 8 clusters
   b. K-means++, usando 8 clusters
   c. DBSCAN con épsilon por defecto
   d. DBSCAN con épsilon 0.7
   e. DBSCAN con épsilon 0.2
   f. DBSCAN con épsilon por defecto, agregando las muestras consideradas ruido a cluster extra
   g. DBSCAN con épsilon 0.7, agregando las muestras consideradas ruido a cluster extra
   h. DBSCAN con épsilon 0.2, agregando las muestras consideradas ruido a cluster extra
   i. Clustering aglomerativo, usando 8 clusters, usando la función AgglomerativeClustering
   j. Repetir todas las pruebas anteriores, después de usar PCA sobre los datos para reducirlos a 2 dimensiones.

5) Analice los resultados obtenidos:
   a. Compare los algoritmos aplicados en base a cuatro métricas (*completeness*, *homogeneity*, *v-measure*, *silhouette*), indicando: (i) cuál variante es mejor según cada métrica y (ii) cuál variante es peor según cada métrica. Se debe considerar tanto los datos originales como los casos en los cuales se aplicó PCA.
   b. Indique en cuáles casos no fue posible calcular las métricas de DBSCAN. Analice el número de clusters obtenidos por DBSCAN y su efecto sobre las métricas. Analice el efecto de considerar o no los outliers de DBSCAN como un cluster extra y su efecto sobre las métricas.
   c. Analice el efecto de usar PCA sobre las métricas obtenidas.

Los informes y códigos deben ser subidos a u-cursos a más tardar el día 23 de Junio a las 23:59. Incluir un corto archivo de texto explicando cómo se utiliza su programa. Las tareas atrasadas serán penalizadas con un punto base por cada día de atraso, incluyendo fines de semana.

Importante: La evaluación de la tarea considerará el correcto funcionamiento del programa, la inclusión de los resultados de los pasos pedidos en el informe, la calidad de los experimentos realizados y de su análisis, la inclusión de las partes importantes del código en el informe, así como la forma, prolijidad y calidad de este. En u-cursos hay un documento indicando la estructura esperada para los informes.

Recordatorio: se debe subir los informes a la plataforma turnitin, en el siguiente link:

https://uchile.turnitin.com/originality/hand-in-link?jwt=eyJ0eXAiOiJKV1QiLCJhbGciOiJIUzI1NiJ9.eyJyZWR3b29kSWQiOiIzYzgxZGQ2Yi01OWE2LTQ2MGEtODE2OC01MGI0OWM1Y2YyYTEiLCJleHAiOjE3MjA5NDM3MDAsImlhdCI6MTcxNzE4NTQzMiwianRpIjoiMmY1N2Y5OGQtYmZhNi00MDJiLTkwYWYtYmIwMWQ3NmI4NmE3IiwidGVuYW50IjoidWNoaWxlIiwiZm9sZGVySWQiOiI3NTdkOGVjMS1kMTg5LTRmMGMtYjJlYy05OGI4NGEyMDRhNjAifQ.paP4oLkxgI8tPF5STsa6kwBK6kAI_yc-Ji-BbEBb1zM

En caso en que Colab genere problemas para leer el archivo xls con pandas, se debe ejecutar la siguiente instrucción en una celda:

```
!pip install --upgrade xlrd
```

Referencias

1. https://scikit-learn.org/stable/modules/clustering.html
2. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.completeness_score.html

3. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.homogeneity_score.html
4. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.v_measure_score.html
5. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html